

JPEG 압축에 강건한 딥페이크 생성 방지 기법에 관한 연구

연구 배경 및 연구 목표

딥페이크 기술의 발달로 다양한 효과를 얻을 수 있지만, 범죄에 악용되는 등 그 부작용이 우려가 되는 상황이다. 기존의 딥페이크 탐지 기술은 악성 콘텐츠의 생성과 유포를 근본적으로 막을 수 없다는 한계가 존재한다.


이에 본 연구는 딥페이크 생성 과정 자체를 사전에 차단하는 것을 목표로 한다. 특히, 생성형 모델에 입력되는 이미지에 적대적 노이즈를 주입하여 정상적인 작동을 방해하는 예방적 방어 기법을 설계하고자 한다. 그러나 기존의 노이즈 기반 방어 기법들은 JPEG와 같은 손실 압축 과정을 거치면 공격 효과가 현저히 감소하는 취약점을 보인다는 문제가 있다.

본 연구는 이러한 문제를 해결하고자 하여, JPEG-robust Ensemble Latent-space Attack(JELA)를 제안한다.

방법론

기존 방법인 LEAT는 노이즈를 효과적으로 생성하기 위해 PGD에서 전체 모델이 아닌 인코더 층만 활용하여 그래디언트를 구한다. 이때 여러 딥페이크 모델에 대한 강건성을 확보하기 위해 각 모델에 정규화된 앙상블을 수행한다. 해당 과정은 다음 수식을 통해 확인할 수 있다:

$$\max_{\eta} \sum_k L(E_k(X), E_k(X + \eta)), \text{ s. t. } \|\eta\|_{\infty} \leq \epsilon. \quad (1)$$



[그림 1] 모델 핵심 구조도

JELA는 기존 LEAT를 확장하여 JPEG 압축에 강건한 노이즈를 생성하는 최적화 문제를 정의한다:

$$\max_{\eta} \sum_k [L(E_k(X), E_k(X + \eta)) + L(E_k(I), E_k(JPEG(X + \eta, q)))], \text{ s. t. } \|\eta\|_{\infty} \leq \epsilon \quad (2)$$

기존 LEAT의 노이즈에 원본 이미지와 압축된 노이즈 이미지의 latent 차이를 최대화하여 JPEG 압축 환경에서도 방어 효과를 유지하도록 한다.

JPEG 압축의 미분 불가능성 문제는 다음 수식을 통해 해결하고자 한다:

$$J := JPEG(X + \mu, q), (detached) \quad (3)$$

JELA의 Computational graph에서 JPEG 압축 후 연결을 의도적으로 끊고, J를 독립변수로 취급한다. 이를 통해 다음 수식처럼 압축된 결과 J에 대해서는 그래디언트 계산이 가능하다는 점을 이용한다:

$$\eta := \eta + \alpha \cdot sign(\nabla_{(X+\eta)} L + \nabla_J L) \quad (4)$$

따라서 J에서 계산된 그래디언트를 원본 노이즈의 업데이트에 직접 사용함으로써 미분 불가능성 문제를 해결하고, JPEG 압축에서 효과적인 노이즈를 생성할 수 있다.

연구 결과


연구 결과를 평가하기 위한 데이터는 CelebA-HQ (Karras et al. 2018)을 사용한다. 노이즈를 생성하기 위한 모델은 StyleCLIP, DiffAE, SimSwap을 사용하며, 추가적으로 블랙박스 환경을 평가하기 위해 AGGAN과 StarGAN을 사용한다.

제안 방법의 성능 평가를 위해 적대적 노이즈 적용 전후 모델 출력 간의 차이를 비교 분석한다. 평가 지표로는 L2 loss, Identity loss, LPIPS를 사용한다. L2 loss는 널리 사용되는 지표이나 픽셀 단위 거리만을 측정한다는 한계를 가진다. 반면 Identity loss와 LPIPS는 각각 의미적 차이와 지각적 차이를 측정하여 공격 효과를 보다 정확하게 평가할 수 있다.

본 연구에서 제안한 방법론의 유효성을 검증하기 위해 LEAT 모델과의 비교 실험을 수행한다. 각 모델이 생성하는 노이즈의 효과를 정량적으로 분석하며, JPEG 압축 후 성능 저하 정도를 측정하여 제안 방법의 강건성을 평가한다.

Attack Models	Metrics↑	White-box				Gray-box			
		LEAT	Ours	LEAT +JPEG	Ours +JPEG	LEAT	Ours	LEAT +JPEG	Ours +JPEG
StyleCLIP	L2 image	0.1547	0.1356	0.0311	0.0608	0.0785	0.1203	0.0252	0.0506
	ID loss	0.5948	0.5743	0.2116	0.3233	0.516	0.5564	0.2020	0.3096
	LPIPS	0.5588	0.5544	0.3773	0.4544	0.5384	0.5451	0.3740	0.4511
DiffAE	L2 image	0.0458	0.0300	0.0038	0.0066	0.0373	0.031	0.0040	0.0069
	ID loss	0.4274	0.3733	0.0672	0.1532	0.4403	0.3723	0.0672	0.1550
	LPIPS	0.5139	0.4246	0.1687	0.2278	0.5043	0.4222	0.1716	0.2283
SimSwap	L2 image	0.0147	0.0144	0.0029	0.0061	0.0138	0.0138	0.0029	0.0058
	ID loss	1.0598	1.0441	0.1703	0.3823	1.0140	1.0387	0.1733	0.3786
	LPIPS	0.1863	0.1859	0.0656	0.1094	0.1885	0.1844	0.0667	0.1103

[표 1] 전체 성능 비교



[그림 2] Gray-box 환경에서 각 모델별 성능 비교

기존 LEAT의 경우 JPEG 압축에 대해 LPIPS에서 최대 67%까지 하락하여 취약한 모습을 보이지만, 우리의 방법을 적용한 이후에는 기존 수치 대비 최대 128% 향상을 보인다.

Attack Models	Metrics	Black-box			
		LEAT	Ours	LEAT+JPEG	Ours +JPEG
AGGAN	L2 image	0.0469	0.0031	0.0540	0.0034
	ID loss	0.3769	0.0704	0.5723	0.0852
	LPIPS	0.4002	0.1967	0.4316	0.2253
StarGAN	L2 image	0.0469	0.0464	0.0044	0.0062
	ID loss	0.3769	0.3881	0.0800	0.0986
	LPIPS	0.4002	0.4012	0.1606	0.1864

[표 2] Black-box 환경의 성능 비교

	Original	LEAT	LEAT+JPEG	Ours	Ours+JPEG
Source					
StyleCLIP					
SimSwap					

[그림 3] White-box 결과

[그림 3]은 화이트박스 환경에서 모델의 성능을 실제로 확인해볼 수 있는 예제이다.

결론 및 참고문헌

본 연구는 기존 적대적 방어 기법이 JPEG 압축 환경에서 쉽게 무력화되는 한계를 해결하기 위해 JPEG-Robust LEAT 기법을 제안한다. 제안 방법은 원본 이미지와 압축 이미지에서 각각 그래디언트를 계산하고 이를 융합하여, 생성형 딥페이크 모델을 효과적으로 방해하는 강건한 적대적 노이즈를 생성한다. 실험 결과, 본 기법은 JPEG 압축 적용 여부와 무관하게 일관된 공격 성능을 유지하며, 기존 방법론 대비 뛰어난 효과를 입증하였다. 향후 연구에서는 계산 효율성 개선과 다양한 실세계 변형 환경으로의 확장 적용을 검토할 계획이다.

[1] Shim, J., & Yoon, H. (2025). LEAT: Towards robust Deepfake disruption in real-world scenarios via latent ensemble attack. Expert Systems with Applications, 279, 127417.
[2] Jeong, J., In, S., Kim, S., Shin, H., Jeong, J., Yoon, S. H., ... & Kim, S. (2024). FaceShield: Defending Facial Image against Deepfake Threats. *arXiv preprint arXiv:2412.09921*.
[3] Dziugaite, G. K., Ghahramani, Z., & Roy, D. M. (2016). A study of the effect of jpg compression on adversarial images. arXiv preprint arXiv:1608.00853.
[4] Zhuang Z, Tomioka Y, Shin J, Okuyama Y. PGD-Trap: Proactive Deepfake Defense with Sticky Adversarial Signals and Iterative Latent Variable Refinement. *Electronics*. 2024; 13(17):3353.